

字符级 GPT 古诗续写实验报告

——手搓因果注意力、前馈子层与加分实验

一、实验目的与任务说明

本实验的核心任务是在一个小型解码器式 Transformer 框架中，补全字符级 GPT 模型的两个关键模块：多头因果自注意力层和位置前馈网络。模型训练目标是根据已经出现的字符预测下一个字符，即 Next Token Prediction。训练完成后，模型可以基于给定起笔字进行古诗风格续写。

本次实验除完成必做部分外，也完成了两个加分项：一是比较不同 temperature 下的生成效果；二是比较不同模型宽度和学习率组合下的验证集 loss。

二、数据准备情况

实验使用的数据集为 Lifan-Z/Chinese-poetries-txt。通过 prepare_data.py 下载并抽样古诗文本，之后构建字符级词表，并按照 9:1 的比例划分训练集和验证集。

项目	结果
数据集总条数	234720
实际抽样条数	100000
poetry.txt 总字符数	约 4482687
词表大小	8319
训练集诗数	90000
验证集诗数	10000
训练集 token 数	4032847
验证集 token 数	449839

三、模型补全部分

1. 多头因果自注意力

在 CausalSelfAttention.forward 中，先通过三个线性层得到 Q、K、V，再把最后一维拆分成多个 head。随后计算 $QK^T / \sqrt{d_head}$ ，并在 softmax 之前加入上三角因果掩码，使当前位置不能看到未来 token。最后用注意力权重与 V 相乘，合并多头结果，并经过输出线性层。

因果掩码的作用是保证自回归生成时模型只能利用当前位置及之前的信息，而不能提前看到后面的真实字符。这样训练过程与实际生成过程保持一致。

2. 位置前馈网络

在 FeedForward 中，实现了 $d_model \rightarrow d_ff \rightarrow GELU \rightarrow d_model$ 的结构，并加入 Dropout。前馈网络对每个位置独立进行非线性变换，用来增强模型的表达能力；注意力层更偏向于建模不同位置之间的关系，而 FFN 负责对每个位置的表示进一步加工。

四、正式训练结果

本次训练在 Mac 的 mps 设备上完成，共训练 3 个 epoch。每个 epoch 约 1563 个 batch，batch_size 为 32。训练过程中验证集 loss 持续下降，说明模型能够从古诗语料中学习到一定的字符连接规律和诗歌语言风格。

Epoch	train_loss	val_loss	说明
1	5.7287	5.1222	保存更优模型
2	5.0222	4.8052	保存更优模型
3	4.7812	4.6467	保存更优模型

最终最佳验证集 loss 为 4.6467。




图 1 训练与验证 loss 曲线

五、续写测试结果

训练完成后，使用 predict.py 进行续写测试。由于 predict.py 的参数为 --prompt，而不是 --start，因此实际运行命令为 python predict.py --prompt 春 --max_new 80 --temperature 0.8。

起笔字：春；max_new：80；temperature：0.8。生成结果如下：

春。

三十三年亦不知，只今山下见青荧。可怜不复秋风雨，争似当年长日长。

溪上无人映翠微，碧城已见等闲来。早朝北望云中出，正值中原种地来。

大龙不及瘦骀骀，真法独来

从结果看，模型已经能生成带有古诗语感的文本，部分句子具有较强的诗歌形式特征，如对仗、景物词和文言表达。但也可以看到，模型规模较小、训练轮数有限，因此仍会出现语义不够连贯、个别句子重复或逻辑跳跃的问题。

六、加分项一：Temperature 对比实验

本实验固定起笔字为“春”，固定 max_new 为 80，分别设置 temperature 为 0.4、0.8、1.2，每个 temperature 各生成 3 次。

temperature	运行编号	起笔字	max_new
0.4	1	春	80
0.4	2	春	80
0.4	3	春	80
0.8	1	春	80
0.8	2	春	80
0.8	3	春	80
1.2	1	春	80
1.2	2	春	80
1.2	3	春	80

temperature=0.4，run=1：

春。
一时中有相，独向公家两门。不似君无处，一尊一夜色。
西山前有客，数年年。
不知来来，一枝青山面。不知无人，一里春风。不如今日，不见长。
一色空无人，一杯。云

temperature=0.4，run=2：

春。
一枝花不应，不知君独与人。
一番春风月，青山。
一点春风，山里来。一时不知此，无时自知。
一时来人得，不复见归。
黄花无心，长日日明。不知今日，春风雨斜。一

temperature=0.4，run=3：

春。
有怜我，风风月。何处，清风吹雨。
一笑当年，金阁无人。
万里天生生，三年年。一夜色，故人。
一径前年年，不须见此。
一舟花花，孤雨，秋风。谁知。
不怜山边春

temperature=0.8，run=1：

春。
何人人乡难，青云首不是听。白，夜来一桃花。紫，人教一舟。扶小卷落，不乘溪不里林。白泉不日直，且期梦流浑。
溪屋归下，迎阴。此处还州，疏一事止千阳。官祖余何事

temperature=0.8，run=2：

春头不召，独闻对经片暮作眠。
小坐中秋，幽人不兼酣。公君行已惯，扁百年岂以民。
高心可蹇江，多。老交所知。留天睡，惊饮差湾。学武荫饥病中颞穴，台鸦趁雪。惟熟，前林

temperature=0.8，run=3:

春。
裴日初如是外，泉秋高老鸟昏。
昌章赋夫可是研，圣畴友已同。一梦中真是不可人，一叶亦及朝亦非。英人人高风如车虎，共归虚旗卷落秋。
传三年年不倚龙，拥殿何必得担

temperature=1.2，run=1:

春春水闷，田。墨材脯毯此揉陀欺锁我，同
于城溪帆来至飞。白后天功游恨，搃父荒林间时。半饥饵独惊财笔，苟图真没玉弃风。投缦莫识王綦，更近菜。甘声
成留仙勋阙，江蓬者提

temperature=1.2，run=2:

春。自寐土空凭花续苑给销，元盛须免习士乾事隍。只家虚相也有坐，应收久能问暮。
弟宁约金门面报炉，坐随田种极儒。臙容镌自饮，况必此由看名且清渐。君已埧鹄姑礲右荣斲绪

temperature=1.2，run=3:

春有与栖踪禅雏，画要无佩阳丝终分交思袍。衣裁纵逢公时刚吏亡接忙。惊轻孤宛读缙钓，指柴通又扃藜隔。三艘贫
从人亲不事居意，只尝封道挂涟。
方如僻谪笔情方阔，冢可瞿邪倩

观察：temperature 较低时，生成文本相对稳定，重复词和常见诗歌意象更多，整体随机性较小；
temperature 提高后，生成文本更发散，词语组合更丰富，但也更容易出现生僻字、语义断裂和不自然搭配。
综合来看，0.8 在稳定性与多样性之间较为均衡。

七、加分项二：超参数对比实验

在同一套数据和相同可比较训练量下，设置三组超参数进行对比。三组实验至少涉及 d_model、n_head、d_ff 和学习率 lr 等超参数变化。

配置	d_model	n_head	n_layer	d_ff	lr	epochs	max_train_batches	val_loss
A baseline	128	4	2	512	0.0003	2	300	6.2569
B wider	192	6	2	768	0.0003	2	300	6.1227
C higher_lr	128	4	2	512	0.001	2	300	5.859

三组实验中，验证集 loss 最低的是 C_higher_lr，val_loss 为 5.8590。在本次较短训练量下，提高学习率到 0.001 的 C_higher_lr 收敛更快，取得了更低的验证 loss。B_wider 增大了模型宽度，理论上表达能力更强，但在只训练 2 个 epoch、每组最多 300 个 batch 的限制下，优势没有完全发挥出来。

八、实验总结

本次实验完成了字符级 GPT 的核心结构补全，并成功完成数据准备、训练、验证、续写和两个加分实验。通过实验可以看到，因果自注意力决定了模型如何在不看到未来字符的条件下整合上下文信息，前馈网络则进一步增强每个位置表示的非线性表达能力。训练结果显示验证集 loss 从 5.1222 下降到 4.6467，说明模型确实学习到了古诗文本中的字符分布规律。

生成结果虽然已经具有古诗形式和部分意象，但由于模型规模、训练轮数和字符级建模方式的限制，文本仍然存在语义跳跃、重复和不够通顺的问题。后续如果继续改进，可以增加训练 epoch、扩大模型规模、调整 block_size，或者使用更稳定的采样策略。

九、完成情况检查

检查项目	完成情况
补全 CausalSelfAttention.forward	已完成
补全 FeedForward. <code>__init__</code> 和 forward	已完成
删除 NotImplementedError	已完成
prepare_data.py 数据准备	已完成
train.py 正式训练	已完成
loss 曲线保存	已完成
predict.py 续写测试	已完成
加分项一：temperature 对比	已完成，3 个 temperature，每个 3 次
加分项二：超参数对比	已完成，3 组配置，涉及两类以上超参数